Passo Seguro — Detector de problemas em calçadas de São Paulo

Applied Computer Vision · Global Solution 2026.2 · CitizenTech · Engenharia de Software 4º ano

Integrantes: Guilherme Morais (RM 551981) · Júlia Marques (RM 98680) · Matheus Gusmão (RM 550826)

Repositório: https://github.com/Passo-Seguro/passo-seguro-visao · **Vídeo:** https://www.youtube.com/watch?v=PzwxpBVbOYc

Resumo

Calçadas danificadas causam quedas e empurram o pedestre para a rua, sobretudo idosos e pessoas com deficiência. As solicitações sobre calçadas no SP156 cresceram mais de 200% entre 2020 e 2025, mas o canal não identifica automaticamente o tipo de problema. Este trabalho treina um detector de objetos YOLO11 para reconhecer problemas de calçada em fotos enviadas pelo app Passo Seguro e em vídeo, em tempo real. O contrato prevê quatro classes (buraco, piso danificado, obstáculo e veículo na calçada); nesta versão, o modelo foi treinado com 2.506 imagens de quatro datasets públicos, que cobrem buraco e piso danificado. Os dados passaram por limpeza: 620 imagens repetidas e um rótulo corrompido foram removidos, e a divisão 70/20/10 manteve cópias da mesma foto no mesmo grupo, evitando vazamento entre treino e teste. Comparamos as versões nano e small com transfer learning a partir do COCO. O small venceu, com mAP50 de 0,679, mAP50-95 de 0,419, precisão de 0,764 e recall de 0,660 no teste. Buraco foi a classe mais difícil (mAP50 de 0,583), por causa de critérios de anotação diferentes entre datasets, sombras e asfalto desgastado. Exportado para ONNX, o modelo responde em 90 ms (p95) em CPU com uma thread, roda a 31 FPS em vídeo e atende o endpoint `POST /deteccoes`, que classifica cada relato do app. Para cobrir as quatro classes e medir o desempenho real em São Paulo, o próximo passo é treinar com fotos próprias das calçadas da cidade.

Introdução

O Passo Seguro é um app (PWA) em que o pedestre de São Paulo reporta um problema na calçada em 30 segundos, descobre quem é o responsável e acompanha o reparo. Segundo levantamento apresentado na Câmara Municipal de São Paulo em agosto de 2026, as solicitações sobre calçadas no SP156 cresceram mais de 200% entre 2020 e 2025, chegando a 49.215. Os canais de denúncia são confusos, e o SP156 não identifica automaticamente o problema nem agrupa relatos repetidos. A Prefeitura já mapeia buracos no asfalto de forma automatizada, enquanto a calçada fica para trás.

A visão computacional resolve a primeira etapa: a partir da foto do relato, o sistema diz qual é o problema e onde ele está na imagem. Essa classificação alimenta a triagem automática, que prioriza e encaminha o relato, e o mapa de problemas. O mesmo modelo roda em vídeo, para uma inspeção contínua durante uma caminhada.

Objetivo

Treinar um detector de objetos para identificar, em fotos e em vídeo em tempo real, problemas de calçada (buraco, piso danificado, obstáculo e veículo estacionado) e entregar a classe e a posição de cada um ao Passo Seguro, para triagem e priorização dos relatos.

Ferramentas

Ferramenta	Para que foi usada
YOLO11 (Ultralytics 8.4)	Detector de um estágio: prevê caixa e classe numa única passada pela rede, o que permite tempo real. Usamos transfer learning a partir dos pesos treinados no COCO, nas versões nano (2,6 M parâmetros) e small (9,4 M). Licença AGPL-3.0, atendida pelo repositório público.
PyTorch 2.14 + CUDA 13	Treino na GPU.
ONNX e ONNX Runtime	Formato aberto do modelo e motor de inferência em CPU. O serviço não usa PyTorch nem Ultralytics, e a imagem Docker fica com 531 MB.
OpenCV e Pillow	Leitura de imagens com a orientação do EXIF, letterbox, desenho das caixas e do FPS, captura de webcam e vídeo, borrão de rostos e placas (LGPD).
FastAPI + Uvicorn	Microsserviço `POST /deteccoes`, no contrato OpenAPI do projeto, com token, limites de tamanho, métricas Prometheus e log sem dados pessoais.
Docker	Empacotamento do serviço (usuário não root, healthcheck).
Datasets públicos	Ultralytics (crack-seg) e Hugging Face (três datasets de buracos de origem Roboflow), com licenças CC BY 4.0 e MIT.
pytest	21 testes do contrato, do pós-processamento e da preparação dos dados.
Hardware de treino	AMD Ryzen 7 9800X3D, 31 GB de RAM, NVIDIA RTX 4080 (16 GB). Treino final: 20,9 min (nano) e 26,2 min (small).

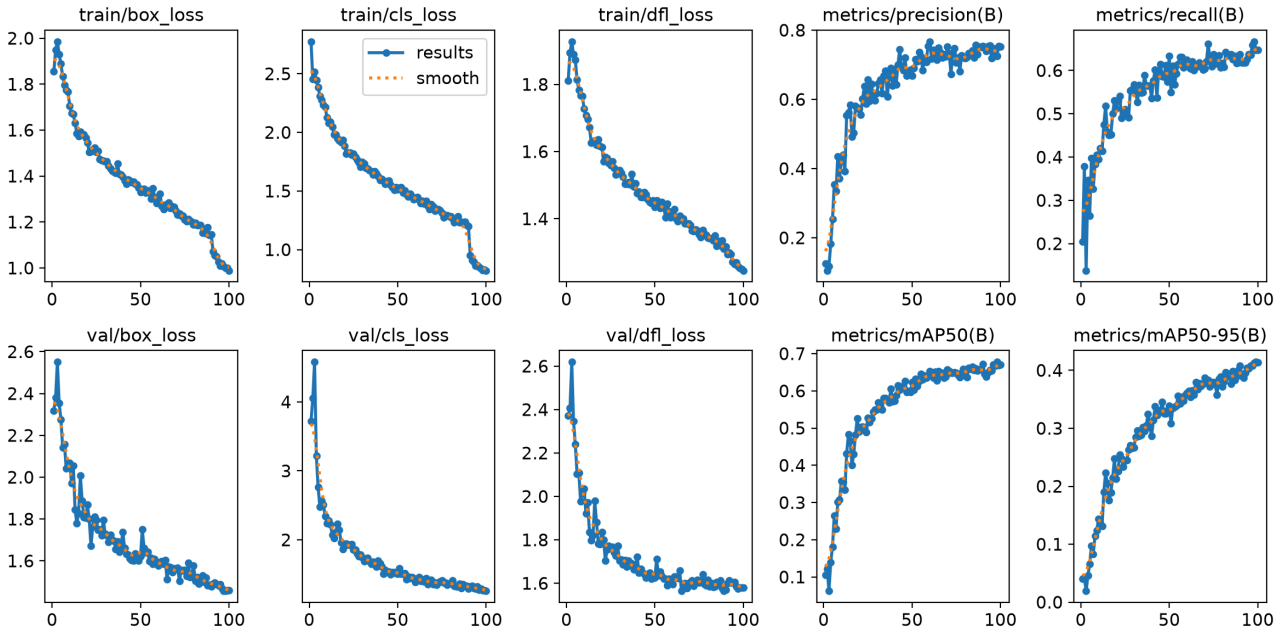
Metodologia

1. **Classes.** Definidas no contrato do projeto (`config/classes.yaml`): `buraco`, `piso_danificado`, `obstaculo` e `veiculo_na_calcada`, nessa ordem, a mesma da API.
2. **Coleta dos datasets públicos.** O script `01a_baixar_publicos.py` baixa quatro datasets abertos que não exigem login e os converte para o formato YOLO (os de origem COCO viram caixas normalizadas; os polígonos de segmentação viram caixas).

Dataset	Licença	Imagens	Caixas
Crack segmentation (Ultralytics)	CC BY 4.0	1.500	1.998 de piso danificado
Road damage v3 (manot)	CC BY 4.0	309	796 de buraco
Pothole Detection (keremberke)	CC BY 4.0	90	120 de buraco
Pothole detection dataset (rupesh002)	MIT	607	1.065 de buraco

1. **Limpeza.** Removemos 620 imagens repetidas, comparando um hash perceptual (dHash): 510 delas eram cópias dentro do próprio dataset manot, algumas presentes ao mesmo tempo no treino e no teste originais; outras 107 se repetiam entre datasets. Também descartamos uma imagem cujo arquivo de rótulo continha texto em vez de caixas.
2. **Remapeamento.** `01_importar_publicos.py` liga cada classe dos datasets às classes do contrato (ex.: `pothole` → `buraco`, `crack` → `piso_danificado`) e descarta o que não serve.

3. **Divisão 70/20/10 por grupo.** `04_montar_dataset.py` divide por foto de origem, e não por arquivo: cópias da mesma foto ficam no mesmo split. Resultado: 1.754 imagens de treino, 501 de validação e 251 de teste.
4. **Baseline.** Nano, 20 épocas, para validar o pipeline de ponta a ponta: mAP50 de 0,638 no teste.
5. **Treino final.** Nano e small, 100 épocas, imagem de 640, parada antecipada com paciência de 20 e augmentation padrão do YOLO (mosaico, espelho, variação de cor e escala). Batch 32 no nano e 16 no small.
6. **Avaliação no teste.** `06_avaliar.py` mede mAP50, mAP50-95, precisão e recall, por classe e no total, e gera a matriz de confusão. `07_analise_erros.py` separa acertos, falsos positivos, falsos negativos e confusões, com as imagens desenhadas.
7. **Exportação e serviço.** `08_exportar_onnx.py` exporta o melhor modelo para ONNX e confere que ONNX e PyTorch dão as mesmas detecções. O serviço aplica o limiar de confiança de 0,4 e o NMS. `09_latencia.py` mede o tempo em CPU.
8. **Tempo real.** `10_tempo_real.py` lê webcam ou vídeo, detecta quadro a quadro com o ONNX em CPU e mostra as caixas e o FPS.



Resultados

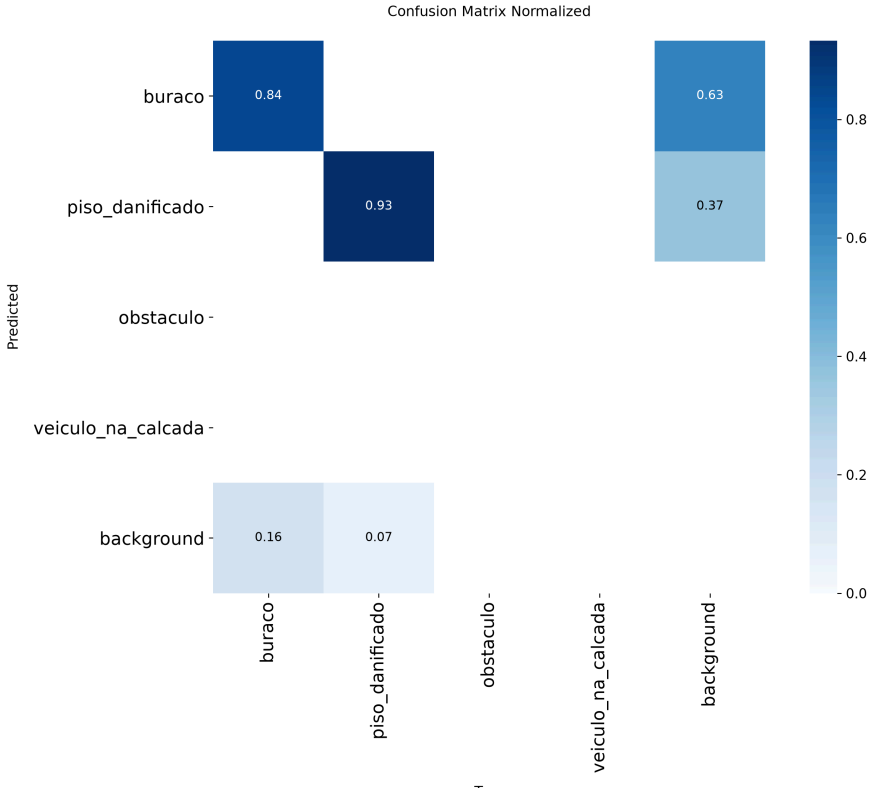
Métricas no teste (251 imagens)

Modelo	mAP50	mAP50-95	Precisão	Recall	ms/imagem (GPU)
YOLO11n baseline (20 épocas)	0,638	0,353	0,726	0,610	2,0
YOLO11n final	0,655	0,408	0,724	0,643	1,9
YOLO11s final	**0,679**	**0,419**	**0,764**	**0,660**	2,9

Modelo	buraco (mAP50 / recall)	piso danificado (mAP50 / recall)
YOLO11n final	0,580 / 0,555	0,730 / 0,731
YOLO11s final	0,583 / 0,581	0,775 / 0,739

O small foi escolhido: tem o maior mAP50-95 no teste e continua rápido o bastante em CPU. O ajuste fino é o que torna a tarefa possível: o YOLO pré-treinado no COCO não tem nenhuma classe de buraco ou rachadura.

Matriz de confusão



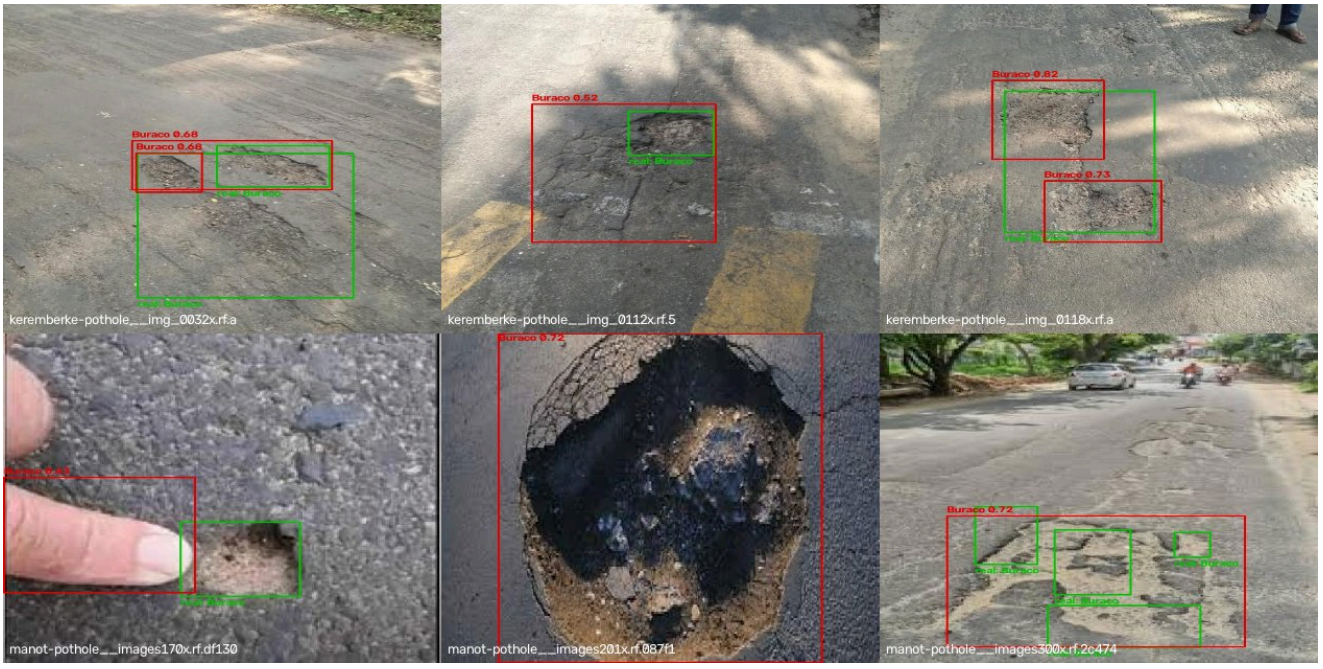
O modelo **nunca confunde buraco com piso danificado**. O erro está na fronteira com o fundo: 84% dos buracos e 93% das rachaduras são detectados, e a maior parte das caixas que sobram (sobre o fundo) é de buraco.

Acertos e erros

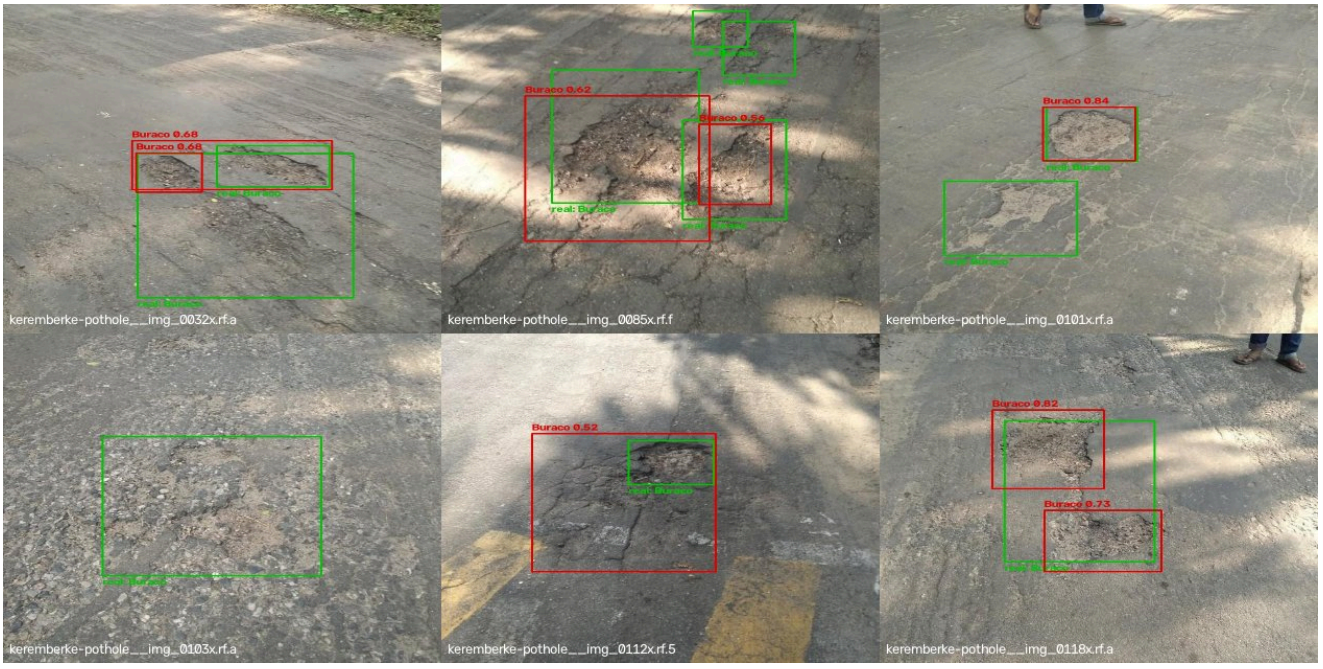
Acertos (vermelho e laranja: previsão; verde: gabarito):



Falsos positivos:



Falsos negativos:



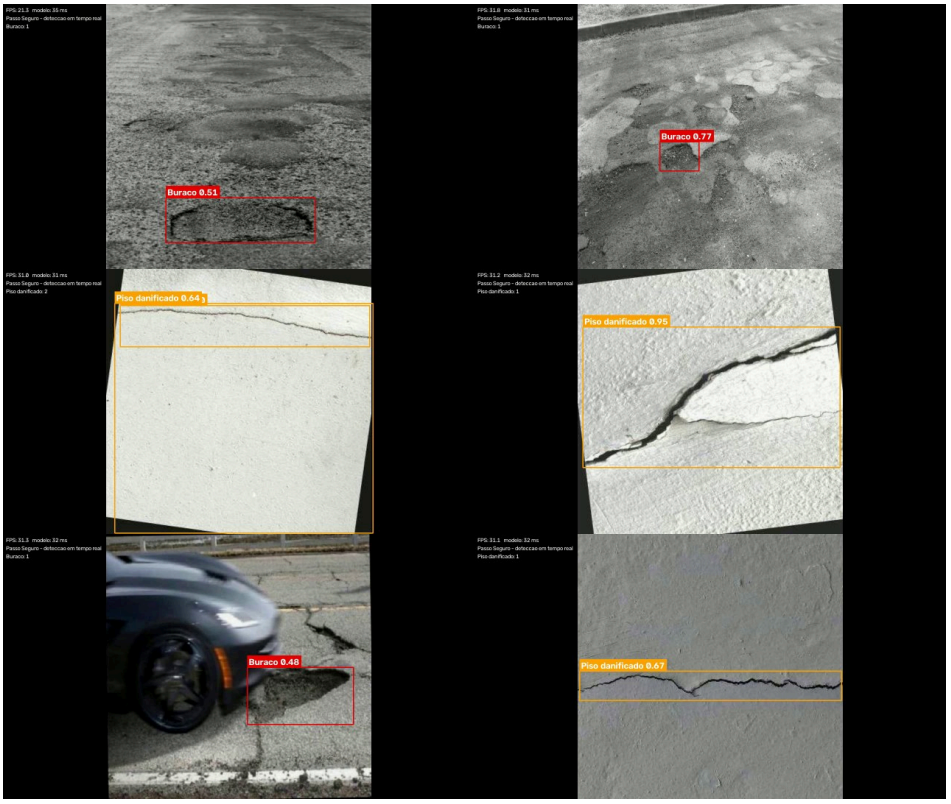
	buraco	piso danificado
Falsos positivos	88	10
Falsos negativos	111	37
Confusão entre classes	0	0

Causas mais comuns, observadas nas imagens:

1. **Granularidade da anotação (a mais frequente):** um dataset marca uma caixa grande em volta de um grupo de buracos; o modelo marca cada buraco (ou o contrário). Conta ao mesmo tempo como falso positivo e falso negativo. **Correção:** padronizar o critério e reanotar, ou treinar com um único dataset de critério consistente.

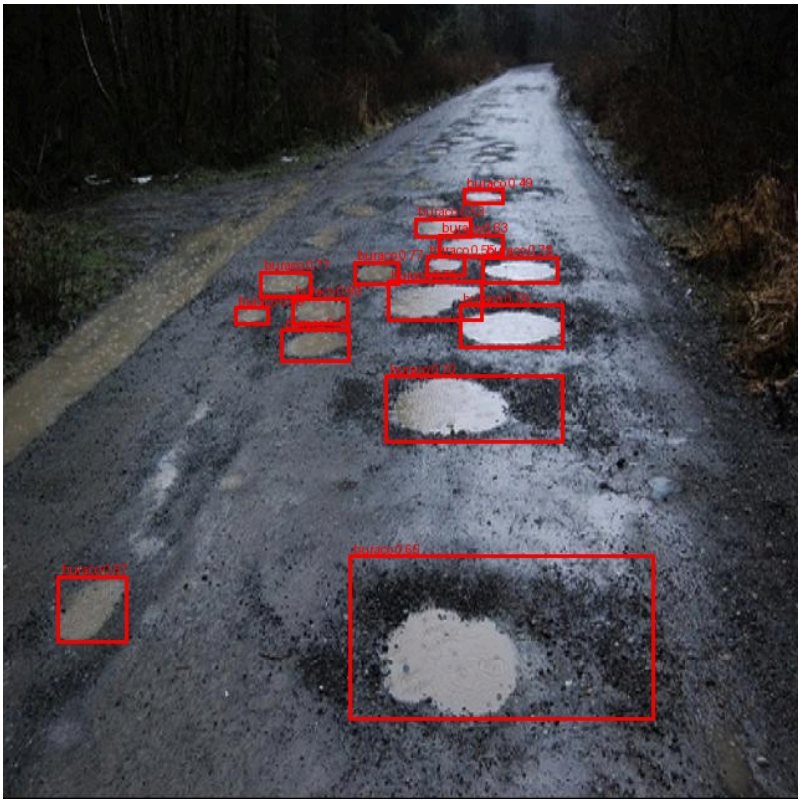
2. **Sombras de árvore e faixas pintadas** confundidas com buraco. **Correção:** mais exemplos negativos (imagens de fundo com sombra).
3. **Asfalto desgastado, de baixo contraste,** não detectado. **Correção:** augmentation de brilho e contraste, e imagens de maior resolução.
4. **Buracos sem anotação** no gabarito: o modelo acerta, mas conta como falso positivo. **Correção:** revisar o rótulo das imagens de teste.

Detecção em tempo real e serviço



CPU (ONNX Runtime)	p50	p95	Imagens/s
1 thread	87 ms	90 ms	11,4
2 threads	49 ms	69 ms	19,1
4 threads	34 ms	48 ms	27,6

Em vídeo, o detector roda a **31 FPS em CPU**. No serviço `POST /deteccoes`, a resposta vem pronta para o app: classe, confiança e caixa normalizada, da maior para a menor confiança.



```
[{"classe": "buraco", "confianca": 0.805, "caixa": {"x": 0.3331, "y": 0.4182, "largura": 0.3729,
"altura": 0.2552}},
 {"classe": "buraco", "confianca": 0.7028, "caixa": {"x": 0.4035, "y": 0.1086, "largura": 0.2167,
"altura": 0.0748}}]
```

Conclusão

O pipeline funciona de ponta a ponta: dados públicos limpos e sem vazamento, treino com transfer learning, avaliação por classe, análise de erros, exportação para ONNX e um serviço em container que classifica a foto do relato em menos de 0,1 s em CPU e roda a 31 FPS em vídeo. O YOLO11s detecta bem piso danificado (mAP50 de 0,775) e razoavelmente buraco (0,583), sem confundir as duas classes. A maior parte dos erros vem da inconsistência de anotação entre datasets, e não do modelo.

Para a triagem do Passo Seguro, esses números bastam como apoio, mas não como decisão final: detecções com confiança abaixo de 0,5 vão para revisão humana, e o cidadão sempre pode corrigir a classe sugerida.

Limitações e próximos passos:

- treinar com fotos próprias das calçadas de São Paulo, separadas por trecho, e só então medir o desempenho real na cidade;
- anotar as classes `obstaculo` e `veiculo_na_calcada`, que ainda não têm exemplos;
- padronizar o critério de anotação de buraco;
- adicionar fotos noturnas e uma classe de ausência de calçada;
- substituir as poucas imagens de banco de imagens dos datasets públicos.